

Relatorio Atualizado - Previsao de Churn de Clientes

Participantes: Nathan Gabriel da Silva - RA: 2077558; Taina de Souza Alvez - RA: 2041631; Julia Soares de Azevedo Lombardi - RA: 2032874.

1. Introducao

Este projeto tem como objetivo prever a chance de cancelamento de clientes de uma empresa de telecomunicacoes. A P2 manteve o mesmo tema e dataset da P1, mas consolidou as melhorias pedidas no feedback: comparacao mais completa dos modelos, interpretacao da Regressao Logistica, discussao do trade-off entre precision e recall, tratamento do desbalanceamento e salvamento do modelo final para uso em uma aplicacao Streamlit.

2. Metodologia

O dataset foi carregado a partir do arquivo data/dataset.csv. A coluna TotalCharges foi convertida para numerica, registros sem valor nessa coluna foram removidos, customerID foi descartada e a variavel alvo Churn foi convertida para 0 e 1. Tambem foi criada a variavel tenure_group, agrupando o tempo de permanencia do cliente em faixas. As variaveis numericas passaram por StandardScaler e as categoricas por OneHotEncoder dentro de um Pipeline, evitando vazamento de dados entre treino e teste.

A divisao foi estratificada em treino, validacao e teste. A estratificacao foi mantida porque a classe churn e menor do que a classe nao churn. Para lidar melhor com esse desbalanceamento, a Regressao Logistica e a Random Forest foram treinadas com class_weight='balanced', e o Gradient Boosting teve o threshold de decisao ajustado com base na curva precision-recall.

3. Comparacao dos Modelos

Resultados no conjunto de validacao:

Modelo	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Gradient Boosting	0.7946	0.6641	0.4599	0.5434	0.8368
Logistic Regression	0.7584	0.5320	0.7567	0.6247	0.8346
Random Forest	0.7783	0.5820	0.5882	0.5851	0.8200

Medias da validacao cruzada estratificada com 5 folds:

Modelo	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Logistic Regression	0.7459	0.5142	0.8020	0.6266	0.8463
Gradient Boosting	0.8032	0.6653	0.5233	0.5856	0.8458
Random Forest	0.7739	0.5658	0.6437	0.6021	0.8271

4. Modelo Final e Threshold

O modelo final mantido foi o Gradient Boosting. Ele apresentou bom desempenho geral em AUC-ROC e foi ajustado com threshold 0.217. Esse ajuste reduz a dependencia do limite padrao 0.50 e deixa mais clara a relacao entre precision e recall. Em churn, um recall maior ajuda a encontrar mais clientes em risco, mas tende a aumentar falsos positivos. Ja uma precision maior torna os alertas mais confiaveis, mas pode deixar passar clientes que realmente cancelariam.

Resultados finais no conjunto de teste:

Cenario	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Threshold padrao 0.50	0.7939	0.6373	0.5214	0.5735	0.8399
Threshold ajustado 0.217	0.7178	0.4823	0.8396	0.6127	0.8399

5. Interpretacao dos Modelos

A Random Forest foi usada para observar importancia das variaveis. As features com maior peso reforcam que tempo de permanencia, tipo de contrato, valor mensal e caracteristicas do plano influenciam diretamente a chance de churn.

Feature	Importance
num__tenure	0.3381
cat__InternetService_Fiber optic	0.1967
num__TotalCharges	0.0766
cat__PaymentMethod_Electronic check	0.0670
num__MonthlyCharges	0.0659
cat__Contract_Two year	0.0596
cat__Contract_One year	0.0580
cat__OnlineSecurity_Yes	0.0173
cat__TechSupport_Yes	0.0155
cat__PaperlessBilling_Yes	0.0140

A Regressao Logistica foi interpretada pelos coeficientes. Coeficientes positivos aumentam a probabilidade estimada de churn, enquanto coeficientes negativos reduzem essa probabilidade. Como os dados passam por preprocessing no Pipeline, a interpretacao considera as variaveis ja transformadas.

Feature	Coefficient
cat__Contract_Two year	-1.4664
num__tenure	-1.2734
cat__InternetService_Fiber optic	1.1228
cat__Contract_One year	-0.9075
cat__tenure_group_37+	0.5946
cat__MultipleLines_Yes	0.4234
cat__tenure_group_13-24	-0.4232
cat__StreamingMovies_Yes	0.4212
cat__tenure_group_25-36	-0.4153
cat__PhoneService_Yes	-0.3837

6. Aplicacao Streamlit

A aplicacao app.py carrega o modelo salvo em model/modelo_final.joblib e o arquivo model/metadata.json, que contem o threshold e a lista de colunas de entrada. O usuario preenche os dados do cliente, o app organiza essas entradas em um DataFrame compativel com o Pipeline e exibe a probabilidade de churn, o threshold usado e a classificacao final.

7. Limitacoes

O modelo usa dados historicos e pode refletir padroes especificos do dataset. A predicao deve ser usada como apoio a decisao, nao como decisao automatica isolada. Alem disso, a aplicacao simula uma entrada manual; em um ambiente real, seria necessario integrar o modelo a uma base atualizada de clientes.

8. Conclusao

A versao final evolui em relacao a P1 porque conecta notebook, modelo salvo, relatorio e app em um fluxo unico. O projeto passa a demonstrar nao apenas a analise e o treinamento, mas tambem a aplicacao pratica do modelo em uma interface funcional para previsao de churn.